



FUNDAÇÃO EDSON QUEIROZ
UNIVERSIDADE DE FORTALEZA - UNIFOR
CENTRO DE TECNOLOGIAS
CURSO MBA EM CIÊNCIA DE DADOS

**PREDIÇÃO DE VENDAS DE PRODUTOS PERECÍVEIS UTILIZANDO
SÉRIES TEMPORAIS CORRELACIONADAS: UM ESTUDO DE CASO
COM A VENDA DE BANANA NO VAREJO**

RODRIGO AMADEU REIS CAVALCANTE

Fortaleza - CE

2026

RODRIGO AMADEU REIS CAVALCANTE

**PREDIÇÃO DE VENDAS DE PRODUTOS PERECÍVEIS UTILIZANDO
SÉRIES TEMPORAIS CORRELACIONADAS: UM ESTUDO DE CASO
COM A VENDA DE BANANA NO VAREJO**

Trabalho de Conclusão do Curso
apresentado ao curso de MBA em Ciência de
Dados da Universidade de Fortaleza.

Turma: T10

Curso: MBA em Ciência de Dados

Matrícula: 2428957

Orientador: Prof. Dr. Jorge Luiz Bezerra de
Araujo

Fortaleza - CE

2026

RODRIGO AMADEU REIS CAVALCANTE

**PREDIÇÃO DE VENDAS DE PRODUTOS PERECÍVEIS UTILIZANDO SÉRIES
TEMPORAIS CORRELACIONADAS: UM ESTUDO DE CASO COM A VENDA
DE BANANA NO VAREJO**

Trabalho de Conclusão do Curso apresentado ao curso de MBA em Ciência de Dados
da Universidade de Fortaleza.

Aprovada em: __/__/____

BANCA EXAMINADORA

Jorge Luiz Bezerra de Araujo

Orientador – Universidade de Fortaleza (UNIFOR)

Nome Completo

Universidade de Fortaleza (UNIFOR)

Nome Completo

Universidade de Fortaleza (UNIFOR)

RESUMO

A previsão de demanda de produtos perecíveis, como frutas, legumes e verduras (FLV), é um desafio relevante para o varejo alimentar. Erros de estimativa podem gerar tanto desperdício por excesso de estoque quanto ruptura por falta de produto.

Este trabalho investigou se a previsão diária das vendas de BANANA em um supermercado pode ser aprimorada ao combinar o histórico do próprio produto com a série temporal de outro item comercializado na loja. A base de dados utilizada contém 1.032.071 registros transacionais de venda, referentes a três meses de operação (novembro de 2022 a janeiro de 2023) de uma única loja. A quantidade diária de BANANA foi obtida pela soma das variedades Prata, Nanica e Maçã.

Para identificar produtos associados a essa demanda, calculou-se a correlação de Pearson entre as séries diárias, primeiro de forma bruta e, em seguida, após a remoção do efeito médio de cada dia da semana, reduzindo o risco de correlações espúrias decorrentes de um padrão de calendário compartilhado por praticamente todo o comércio da loja. A seleção final do produto parceiro foi restrita a itens do mesmo departamento de FLV/hortifrúti, resultando na escolha da ABÓBORA CABOCLA KG, com defasagem de um dia.

Seis abordagens preditivas foram comparadas: um modelo ingênuo, um modelo ingênuo sazonal, uma média móvel, uma regressão linear e dois modelos de conjunto de árvores (Random Forest e Gradient Boosting), todos utilizando variáveis defasadas e de calendário. O modelo Random Forest univariado apresentou o melhor desempenho entre os modelos baseados somente no histórico da BANANA, com RMSE de 41,06 kg no período de teste (14 dias).

Ao incorporar as variáveis defasadas da Abóbora Cabocla, o RMSE do modelo combinado caiu para 40,50 kg, uma redução de aproximadamente 1,4%, ainda que o MAE e o MAPE não tenham apresentado a mesma melhora. Como complemento, testou-se também uma previsão específica por dia da semana, de interesse direto para a operação de compra e reposição da loja.

Conclui-se que séries temporais de produtos do mesmo departamento podem conter informação adicional relevante para a previsão da BANANA, mas o ganho observado foi modesto e não uniforme entre as métricas avaliadas, reforçando a necessidade de avaliações com maior volume histórico antes de qualquer aplicação operacional.

Palavras-chave: Previsão de demanda; Séries temporais; Correlação; Aprendizado de máquina; FLV; Banana; Varejo.

ABSTRACT

Demand forecasting for perishable products, such as fruits and vegetables, is a relevant challenge for food retail. Estimation errors can lead to both waste from excess inventory and stockouts.

This study investigated whether the daily forecast of BANANA sales in a supermarket can be improved by combining the product's own history with the time series of another item sold in the same store. The dataset used contains 1,032,071 transactional sales records covering three months of operation (November 2022 to January 2023) of a single store. The daily BANANA quantity was obtained by summing the Prata, Nanica and Maça varieties.

To identify products associated with this demand, the Pearson correlation between the daily series was computed, first in raw form and then after removing the average effect of each day of the week, reducing the risk of spurious correlations arising from a calendar pattern shared by virtually every product sold in the store. The final selection of the partner product was restricted to items from the same produce department, resulting in the choice of ABOBORA CABOCLA KG (a local squash), with a one-day lag.

Six predictive approaches were compared: a naive model, a seasonal naive model, a moving average, a linear regression and two tree-ensemble models (Random Forest and Gradient Boosting), all using lagged and calendar variables. The univariate Random Forest model achieved the best performance among the models based solely on BANANA history, with an RMSE of 41.06 kg over the 14-day test period.

When the lagged Abobora Cabocla variables were added, the combined model's RMSE dropped to 40.50 kg, a reduction of approximately 1.4%, although MAE and MAPE did not show the same improvement. As a complement, a day-of-week-specific forecast was also tested, of direct interest to the store's purchasing and replenishment operations.

The results suggest that time series from products of the same department may contain additional information relevant to BANANA forecasting, but the observed gain was

modest and inconsistent across metrics, reinforcing the need for evaluations with a longer historical window before any operational application.

Keywords: Demand forecasting; Time series; Correlation; Machine learning; Produce; Banana; Retail.

SUMÁRIO

1. INTRODUÇÃO.....	10
1.1 Contextualização.....	10
1.2 Justificativa.....	11
1.3 Objetivo	11
1.4 Metodologia proposta	12
2. REFERENCIAL TEÓRICO.....	13
2.1 Perecibilidade e perdas na cadeia de frutas, legumes e verduras	13
2.2 A cultura da banana e sua relevância econômica no Nordeste e no Ceará	13
2.3 Previsão de demanda e séries temporais no varejo	14
2.4 Correlação entre séries temporais e o risco de correlações espúrias	15
2.5 Aprendizado de máquina aplicado à previsão de vendas	16
2.6 Como funcionam os modelos utilizados	16
3. METODOLOGIA	20
3.1 Base de dados	21
3.2 Análise e tratamento da qualidade dos dados	22
3.3 Definição do produto-alvo.....	23
3.4 Construção da série temporal.....	24
3.5 Investigação do comportamento temporal da BANANA.....	24
3.6 Seleção das séries dos demais produtos	24
3.7 Análise de correlação bruta.....	25
3.8 Controle do efeito de dia da semana	25
3.9 Restrição ao domínio de FLV/hortifrúti e defasagem temporal	26
3.10 Preparação das variáveis para modelagem.....	27
3.11 Separação temporal entre treino e teste.....	27
3.12 Modelos de previsão	27
3.13 Complemento: previsão específica por dia da semana.....	28

3.14 Métricas de avaliação	29
3.15 Síntese do procedimento metodológico	29
4. RESULTADOS E DISCUSSÃO	30
4.1 Visão geral do faturamento e caracterização da série de BANANA.....	30
4.2 Comportamento das vendas segundo o dia da semana.....	31
4.3 Correlação bruta entre as séries dos produtos	33
4.4 Efeito do controle do dia da semana sobre a correlação	35
4.5 Seleção do produto parceiro dentro do domínio de FLV/hortifrúti	37
4.6 Avaliação dos modelos univariados.....	40
4.7 Modelo combinado: BANANA e Abóbora Cabocla	42
4.8 Discussão dos resultados.....	44
4.9 Implicações gerenciais para produtos perecíveis	45
4.10 Limitações do estudo.....	46
4.11 Complemento: previsão específica por dia da semana.....	47
5. CONCLUSÃO	50
REFERÊNCIAS	53

1. INTRODUÇÃO

1.1 Contextualização

A banana é uma das frutas mais consumidas no Brasil e no mundo. Ela tem bom valor nutricional, custo baixo e fica disponível o ano inteiro (SENA, 2011).

O Nordeste é a principal região produtora de banana do país, com destaque para Bahia, Pernambuco, Rio Grande do Norte e Ceará, onde a produção se concentra em polos de fruticultura irrigada (SENA, 2011). Em âmbito nacional, o Brasil é o quarto maior produtor mundial de banana, com produção anual de aproximadamente 6,6 milhões de toneladas em cerca de 455 mil hectares (EMBRAPA, 2026).

No Ceará, a fruticultura ocupa cerca de 45 mil hectares em 64 municípios, organizados em seis polos de irrigação. A banana está entre as principais frutas exportadas pelo estado, junto com melão, coco, maracujá, melancia, mamão e manga (CEARÁ, 2026).

O supermercado cujos dados de venda são analisados neste trabalho está localizado em Fortaleza, capital do Ceará (IBGE, 2026).

No varejo, a relevância da banana não está apenas na produção agrícola, mas também na complexidade de sua comercialização como produto perecível. Frutas, legumes e verduras (FLV) têm vida de prateleira curta, sujeita a perdas quando a quantidade comprada ou repostada não corresponde à demanda real dos consumidores.

Esse descompasso ocorre em duas direções. O excesso de estoque resulta em descarte de produtos deteriorados. A insuficiência de estoque resulta em ruptura de gôndola e perda de vendas. Em ambos os casos, o custo recai sobre o varejista.

Este trabalho parte de um conjunto de dados reais de vendas de um supermercado, com os itens comercializados por ticket (cupom de venda), seus valores e as datas das transações, ao longo de três meses de operação. A base foi construída a partir desses registros e é detalhada na Seção 3.1, com uma amostra disponibilizada publicamente para consulta (ver link no repositório de código: <https://github.com/rodrigoacavalcante/artigo-mba-serie-temporal>).

A partir dessa base, investigou-se, especificamente para a BANANA, se o comportamento de venda apresenta padrões temporais identificáveis e se séries temporais de outros produtos comercializados na mesma loja guardam associação com essas vendas a ponto de contribuir para a previsão de demanda do produto.

1.2 Justificativa

A dificuldade de prever com precisão a demanda de produtos perecíveis, especialmente a banana, utilizando apenas o histórico de vendas do próprio produto, é o problema central que motiva este estudo.

Erros de previsão em FLV geram excesso de estoque, desperdício e perdas financeiras, dada a alta perecibilidade desses produtos. Por outro lado, uma previsão abaixo da demanda provoca falta do produto e perda de vendas. Aumentar a precisão da previsão pode, portanto, contribuir para uma gestão de estoque mais eficiente.

Na prática, supermercados costumam dimensionar a compra e a reposição de FLV com base na experiência de quem trabalha na loja e em médias históricas simples, sem necessariamente explorar as relações entre as vendas de diferentes produtos.

Se o comportamento de compra por trás da venda de banana estiver associado ao de outros itens do hortifrúti — por integrarem a mesma cesta de compras, por exemplo, ou por reagirem de forma semelhante a fatores como clima ou dia da semana —, informações dessas séries correlacionadas poderiam, em tese, ser incorporadas a um modelo preditivo para melhorar sua acurácia.

Do ponto de vista acadêmico, o estudo também se justifica pela oportunidade de aplicar, sobre uma base transacional real, um procedimento estruturado de análise de séries temporais e de correlação entre produtos, com atenção a armadilhas metodológicas comuns nesse tipo de análise, como a confusão entre correlação e causalidade e o risco de correlações espúrias por padrões de calendário compartilhados.

1.3 Objetivo

O objetivo geral deste trabalho é investigar se a previsão diária das vendas de BANANA em um supermercado pode ser aprimorada ao se combinar o histórico do

próprio produto com a série temporal de outro produto comercializado na loja que apresente associação estatística relevante com essas vendas.

Para alcançar esse objetivo geral, foram definidos os seguintes objetivos específicos:

- a) caracterizar a série temporal diária de vendas da BANANA, identificando padrões de calendário e de dependência temporal;
- b) investigar a existência de correlações relevantes entre a série da BANANA e as séries diárias dos demais produtos comercializados na loja, distinguindo associações genuínas de associações decorrentes de padrões de calendário compartilhados;
- c) construir e comparar modelos de previsão baseados exclusivamente no histórico da própria BANANA, incluindo uma previsão complementar específica por dia da semana;
- d) avaliar se a incorporação de um produto identificado como correlacionado melhora o desempenho preditivo em relação ao modelo baseado apenas na própria BANANA.

1.4 Metodologia proposta

Para atingir os objetivos descritos, foi adotada uma abordagem quantitativa e experimental, estruturada em etapas sucessivas. As etapas incluem preparação e análise exploratória da base transacional, definição do produto-alvo e construção de séries temporais diárias.

As etapas seguintes envolvem a investigação de padrões de calendário, a seleção e a análise de correlação entre produtos, a construção de variáveis preditivas e o treinamento e a comparação de modelos.

Por fim, o desempenho dos modelos é avaliado sobre um período de teste separado temporalmente do período de treinamento. O detalhamento completo dessa metodologia, incluindo as decisões tomadas em cada etapa, é apresentado na Seção 3.

2. REFERENCIAL TEÓRICO

2.1 Perecibilidade e perdas na cadeia de frutas, legumes e verduras

Frutas, legumes e verduras (FLV) são caracterizados por uma vida útil curta em comparação com produtos industrializados de mercearia, o que torna sua gestão de estoque particularmente sensível a erros de previsão de demanda.

Diferentemente de produtos não perecíveis, para os quais o excesso de estoque representa principalmente um custo de capital imobilizado, o excesso de estoque em FLV tende a se converter diretamente em perda física, pois o produto se deteriora antes de ser vendido.

Por outro lado, a insuficiência de estoque resulta em ruptura de gôndola, com impacto direto sobre a venda do dia e, potencialmente, sobre a percepção do cliente em relação à variedade e ao frescor da seção.

A acurácia da previsão de demanda assume, assim, papel central na gestão de perdas em FLV. Quanto mais próxima a estimativa de compra ou reposição estiver da demanda real, menor tende a ser tanto o volume descartado por deterioração quanto a receita perdida por falta de produto.

2.2 A cultura da banana e sua relevância econômica no Nordeste e no Ceará

A banana é uma das frutas mais cultivadas e consumidas no mundo, com destaque nutricional pelo teor de vitaminas, fibras e potássio (SENA, 2011).

O Brasil é o quarto maior produtor mundial de banana, com produção anual de aproximadamente 6,6 milhões de toneladas, cultivadas em cerca de 455 mil hectares distribuídos pelos 26 estados e pelo Distrito Federal. São Paulo, Bahia e Minas Gerais lideram os volumes de produção (EMBRAPA, 2026).

Cerca de metade dessa produção nacional provém da agricultura familiar. O setor gera aproximadamente R\$ 13,8 bilhões e 500 mil empregos diretos por ano, refletindo a relevância socioeconômica da cultura, favorecida pelo baixo custo e pelo consumo difundido em todas as faixas de renda e idade no país (EMBRAPA, 2026).

A Região Nordeste concentra parte relevante da produção nacional, beneficiada pela estrutura de irrigação de seus polos de fruticultura (SENA, 2011).

No Ceará, a fruticultura irrigada ocupa aproximadamente 45 mil hectares em 64 municípios, organizados em seis polos de produção. A banana está entre as principais frutas exportadas pelo estado, com mercados em expansão inclusive para a Ásia e o Oriente Médio (CEARÁ, 2026).

A cultura enfrenta também desafios fitossanitários relevantes, como a Sigatoka-amarela, a Sigatoka-negra e o mal-do-Panamá causado pelo fungo *Fusarium*, incluindo a variante Raça Tropical 4, já identificada em países vizinhos e considerada um risco iminente para a bananicultura brasileira. Em resposta, cultivares resistentes como a BRS Princesa e a BRS Platina têm sido desenvolvidas e testadas (EMBRAPA, 2026).

Apesar dessa relevância produtiva, a banana permanece um produto altamente perecível também na ponta do varejo. Isso reforça a pertinência de investigar métodos que aprimorem a previsão de sua demanda diária no ambiente de uma loja física, foco deste trabalho.

2.3 Previsão de demanda e séries temporais no varejo

Uma série temporal é uma sequência de observações de uma variável ao longo do tempo, tipicamente apresentando componentes de tendência, sazonalidade e variação residual (OLIVEIRA et al., 2021).

No varejo, séries de vendas diárias costumam apresentar sazonalidade de curto prazo associada ao dia da semana, com maior movimento aos finais de semana. Também costumam apresentar dependência temporal: o valor observado em um dia tende a guardar relação estatística com os valores observados em dias anteriores (FERREIRA et al., 2017).

Modelos de previsão ingênuos (naive), que repetem o último valor observado ou o valor observado no mesmo dia da semana anterior, são frequentemente utilizados como referência mínima de comparação. Qualquer modelo mais sofisticado deve, no mínimo, superar esse tipo de estimativa simples para justificar sua adoção (OLIVEIRA et al., 2021).

A avaliação de modelos de previsão costuma ser feita por métricas de erro como o Erro Absoluto Médio (MAE) e a Raiz do Erro Quadrático Médio (RMSE), que expressam a magnitude dos erros na unidade da variável-alvo, e o Erro Percentual Absoluto Médio (MAPE), que expressa o erro em termos relativos.

2.4 Correlação entre séries temporais e o risco de correlações espúrias

O coeficiente de correlação de Pearson mede o grau de associação linear entre duas variáveis numéricas, assumindo valores entre -1 e 1.

Quando aplicado a séries temporais, esse coeficiente é frequentemente utilizado como instrumento exploratório para identificar pares de séries que se movem de forma semelhante ao longo do tempo. É importante destacar, no entanto, que uma correlação estatisticamente relevante entre duas séries não implica relação causal entre elas.

Duas séries temporais podem apresentar correlação elevada por mero acaso de amostragem, sem qualquer relação real entre si.

No contexto de vendas no varejo, um fator de confusão particularmente relevante é o padrão de calendário. Praticamente todo produto de compra frequente tende a vender mais em determinados dias da semana, de modo que dois produtos completamente independentes entre si podem apresentar correlação elevada apenas por compartilharem esse comportamento semanal.

Além disso, quando um grande número de séries é comparado simultaneamente a uma série de referência, é estatisticamente esperado que algumas delas apresentem correlação elevada por mero acaso, mesmo sem qualquer relação real — problema conhecido como comparações múltiplas.

Esses efeitos tornam necessário um cuidado metodológico adicional antes de se interpretar uma correlação elevada como evidência de associação útil para fins preditivos. Esse cuidado orientou diretamente as decisões metodológicas adotadas neste trabalho, detalhadas na Seção 3.

2.5 Aprendizado de máquina aplicado à previsão de vendas

Além dos modelos estatísticos clássicos, algoritmos de aprendizado de máquina supervisionado têm sido amplamente empregados em problemas de previsão de séries temporais, tratados como um problema de regressão a partir de variáveis defasadas (lags), médias móveis e variáveis de calendário.

A regressão linear múltipla é um modelo de referência simples e interpretável, adequado inclusive para conjuntos de dados de tamanho limitado.

Modelos de conjunto baseados em árvores de decisão, como o Random Forest e o Gradient Boosting, combinam múltiplas árvores para capturar relações não lineares entre as variáveis preditoras e a variável-alvo.

Esses modelos geralmente custam alguma interpretabilidade direta dos coeficientes, ainda que seja possível extrair medidas de importância de cada variável para o modelo treinado (GÉRON, 2022).

As implementações utilizadas neste trabalho para os modelos de regressão linear, Random Forest e Gradient Boosting, bem como para as métricas de avaliação, foram obtidas da biblioteca scikit-learn (PEDREGOSA et al., 2011). A manipulação e a agregação dos dados transacionais foram realizadas com a biblioteca pandas, ambas em linguagem Python.


2.6 Como funcionam os modelos utilizados

Esta seção ilustra, de forma didática e com dados sintéticos (não relacionados à base de BANANA), o princípio de funcionamento de cada família de modelo empregada neste trabalho.

A regressão linear busca a reta que melhor resume a relação entre uma variável explicativa e a variável que se deseja prever, minimizando a soma dos quadrados das distâncias entre os valores observados e a reta ajustada. A Figura 1 ilustra esse princípio.

Figura 1 – Ilustração didática de uma regressão linear sobre dados sintéticos. A reta vermelha é ajustada de modo a minimizar a soma dos quadrados das distâncias verticais (em cinza) entre cada ponto observado e a própria reta. No contexto deste trabalho, a

variável explicativa corresponde, por exemplo, a um valor defasado da série de BANANA, e a variável prevista corresponde à venda do dia seguinte.




Fonte: Elaborado pelo autor (2026), com dados sintéticos gerados para fins didáticos.

Uma árvore de decisão divide progressivamente os dados em grupos, a partir de perguntas sobre as variáveis explicativas (por exemplo, "a venda de 7 dias atrás foi maior que determinado valor?"), até chegar a grupos mais homogêneos, para os quais é atribuído um valor médio de previsão. A Figura 2 ilustra uma árvore simples, treinada sobre dados sintéticos.

Figura 2 – Ilustração didática de uma árvore de decisão com profundidade 2, treinada sobre dados sintéticos com duas variáveis explicativas. Cada retângulo representa uma pergunta sobre os dados (por exemplo, se a primeira variável é menor ou igual a determinado valor); os retângulos finais (folhas) mostram o valor médio previsto para o grupo de observações que chegou até ali. O Random Forest combina centenas de árvores como essa, cada uma treinada com uma amostra diferente dos dados, e calcula a média das previsões individuais.

Árvore de decisão: divide os dados em grupos por perguntas sucessivas




Fonte: Elaborado pelo autor (2026), com dados sintéticos gerados para fins didáticos.

O Gradient Boosting segue uma lógica diferente da do Random Forest: em vez de treinar árvores independentes, treina uma sequência de árvores pequenas, em que cada nova árvore aprende a corrigir o erro (resíduo) que restou da previsão acumulada das árvores anteriores (GÉRON, 2022). A Figura 3 ilustra esse processo em três estágios.

Figura 3 – Ilustração didática do funcionamento do Gradient Boosting sobre uma série sintética (pontos azuis). Cada painel mostra a previsão acumulada (linha verde) após um número crescente de árvores: com 1 árvore, a previsão é praticamente uma média simples; com 5 árvores, já captura o formato geral da série; com 50 árvores, acompanha

de forma bem mais próxima as oscilações dos dados observados. É esse mecanismo de correção sucessiva do erro que permite ao Gradient Boosting capturar relações mais complexas do que um único modelo linear.

Gradient Boosting: cada nova árvore corrige o erro que restou da anterior



Fonte: Elaborado pelo autor (2026), com dados sintéticos gerados para fins didáticos.

3. METODOLOGIA


Este estudo adotou uma abordagem quantitativa e experimental, baseada na análise de dados transacionais de vendas de um supermercado.

Todo o processamento, as análises e os modelos descritos nesta seção foram implementados em Python, em um notebook Jupyter único e reproduzível (`analise_banana.ipynb`). Cada resultado numérico apresentado neste trabalho corresponde diretamente à saída de uma célula de código executada.

O processo foi organizado nas seguintes etapas: análise exploratória e de qualidade dos dados; definição do produto-alvo; construção da série temporal diária; investigação de padrões temporais.

As etapas seguintes foram: seleção de produtos candidatos; análise de correlação bruta e com controle do efeito de dia da semana; restrição da escolha do produto parceiro ao mesmo departamento de FLV; construção de variáveis preditivas; separação temporal entre treino e teste; construção dos modelos de previsão; e avaliação por métricas de erro. A Figura 4 resume visualmente esse caminho, do problema até o resultado esperado.

Figura 4 – Visão geral do problema e da metodologia de solução, do levantamento dos dados de venda até o resultado esperado de maior acurácia na predição da BANANA e possível redução de perdas em FLV.



Fonte: Elaborado pelo autor com apoio da ferramenta ChatGPT (OpenAI) para geração do infográfico (2026).

3.1 Base de dados

A base utilizada no estudo contém registros transacionais de vendas realizadas em um supermercado, no período compreendido entre 1º de novembro de 2022 e 31 de janeiro de 2023.

O conjunto de dados possui 1.032.071 registros e sete variáveis relacionadas às transações de venda. Cada linha corresponde a um item comercializado dentro de um ticket (cupom de venda).

Por motivos de confidencialidade comercial, a base completa não é disponibilizada publicamente. Uma amostra representativa dos dados, suficiente para verificação da estrutura descrita nesta seção, está disponível no seguinte repositório: <https://github.com/rodrigoacavalcante/artigo-mba-serie-temporal>.

As variáveis disponíveis permitem identificar a transação, o instante da venda, a loja, o produto comercializado, sua quantidade e seu valor unitário, conforme apresentado na Tabela 1.

Tabela 1 – Descrição das variáveis do conjunto de dados.

Variável	Descrição	Tipo de informação
sale_id	Identificador da transação de venda (ticket)	Identificador
date_time	Data e hora em que a transação foi realizada	Data/Hora
store_id	Identificador da loja onde ocorreu a venda	Identificador
unit_value	Valor unitário do produto comercializado	Numérica
amount	Quantidade comercializada do produto	Numérica
description	Descrição comercial do produto	Categórica/Textual
product_id	Identificador único do produto	Identificador

Fonte: Elaborado pelo autor a partir da base de dados utilizada no estudo (2026).

Foi identificada apenas uma loja (store_id único) no conjunto de dados, com 129.909 tickets distintos, envolvendo 10.117 produtos diferentes. O faturamento total aproximado no período foi de R\$ 10.245.228,80.

Como há apenas uma loja, não foram necessárias comparações ou agregações entre diferentes estabelecimentos.

3.2 Análise e tratamento da qualidade dos dados

Inicialmente foi realizada uma análise exploratória para compreender a estrutura, a consistência e a qualidade das informações disponíveis. Foram avaliados valores ausentes, registros idênticos, distribuição das variáveis numéricas e cobertura do calendário de vendas.

Não foram identificados valores ausentes nas sete variáveis originais, tampouco valores de amount ou unit_value negativos ou iguais a zero.

A inspeção revelou a presença de 81.114 linhas totalmente duplicadas (mesmo ticket, produto, valor e quantidade). Como a base não contém um identificador individual do item de ticket que permita distinguir com segurança uma duplicidade técnica de múltiplas unidades registradas separadamente na mesma transação, essas linhas foram preservadas.

Essa decisão não compromete a análise seguinte, que trabalha por agregados diários: eventuais repetições legítimas são simplesmente somadas à quantidade do dia.

A verificação da continuidade temporal identificou duas datas sem qualquer transação registrada na loja: 25 de dezembro de 2022 e 1º de janeiro de 2023. Ambas foram interpretadas como dias sem operação comercial, e não como dias com demanda igual a zero, e por isso não foram preenchidas artificialmente na construção das séries diárias.

3.3 Definição do produto-alvo

A identificação inicial de produtos cuja descrição continha a palavra "BANANA" retornou 67 descrições distintas, incluindo itens industrializados que utilizam banana apenas como ingrediente (por exemplo, biscoitos, barras de cereal e bebidas lácteas sabor banana).

Por esse motivo, as descrições foram inspecionadas para isolar os produtos correspondentes diretamente à fruta comercializada por peso, resultando em três variedades: BANANA PRATA KG (9.482 registros, 10.691,84 kg no período), BANANA NANICA KG (1.527 registros, 1.506,53 kg) e BANANA MACA KG (874 registros, 849,96 kg).

Optou-se por definir o produto-alvo como a soma diária das três variedades, resultando em uma única série "BANANA (total)", com 13.048,33 kg comercializados no período e presença em 100% dos 90 dias operacionais.

Essa escolha foi motivada pela perspectiva de gestão de FLV do estudo: do ponto de vista de compra e reposição na seção de hortifrúti, o que importa operacionalmente é a demanda agregada pelo fruto banana, independentemente da variedade especificamente adquirida pelo cliente.

3.4 Construção da série temporal

A variável `date_time` foi convertida para formato temporal. Em seguida, os registros foram agregados por data e produto por meio da soma da variável `amount`, produzindo séries temporais diárias de quantidade comercializada.

Para a matriz de produtos utilizada nas análises de associação e modelagem, os dias operacionais sem registro de venda de determinado produto foram representados por quantidade igual a zero. Dessa forma, distinguiu-se a ausência de venda de um produto em um dia de funcionamento da ausência de operação da loja identificada na Seção 3.2.

3.5 Investigação do comportamento temporal da BANANA

A série diária da BANANA foi analisada descritivamente para caracterizar sua distribuição e variabilidade. As quantidades comercializadas também foram comparadas segundo o dia da semana, com o objetivo de investigar a existência de comportamento semanal recorrente. Os resultados dessa caracterização são apresentados na Seção 4.1.

3.6 Seleção das séries dos demais produtos

Para investigar se outros produtos apresentavam informações temporalmente associadas às vendas de BANANA, foram construídas séries diárias para os produtos presentes na base.

Como parte dos produtos apresentava comercialização esporádica, foi adotado um critério mínimo de cobertura temporal: apenas produtos comercializados em pelo menos 90% dos 90 dias operacionais (ou seja, em pelo menos 81 dias) foram considerados elegíveis para a análise de correlação. Esse critério resultou em 482 produtos elegíveis, de um total de 10.117 produtos distintos na base.

3.7 Análise de correlação bruta

A associação linear entre as séries foi investigada por meio do coeficiente de correlação de Pearson, calculado entre a série diária da BANANA e a série diária de cada um dos 482 produtos elegíveis, no mesmo dia (defasagem zero).

$$r = \sum (x_i - \bar{x})(y_i - \bar{y}) / \sqrt{[\sum (x_i - \bar{x})^2 \cdot \sum (y_i - \bar{y})^2]}$$

Equação 1 – Coeficiente de correlação de Pearson entre duas séries X e Y.

A correlação foi utilizada exclusivamente como instrumento exploratório de seleção de variáveis, e não como evidência de relação causal entre os produtos.

Como discutido na Seção 2.4, produtos de compra frequente tendem a compartilhar um padrão de calendário, com maior volume de vendas aos finais de semana. Esse padrão pode inflar artificialmente a correlação observada entre produtos sem qualquer relação de negócio entre si. Essa hipótese foi testada de duas formas complementares, descritas nas Seções 3.8 e 3.9.

3.8 Controle do efeito de dia da semana

Para reduzir a influência de padrões semanais compartilhados, foi calculada, para cada produto, a quantidade média correspondente a cada dia da semana ao longo do período.

Essa média foi subtraída da quantidade observada, produzindo uma série residual, utilizada na análise de associação, inclusive para a BANANA.

$$\text{resíduo}(p, t) = \text{quantidade}(p, t) - \text{média}(p, \text{dia_da_semana}(t))$$

Equação 2 – Remoção do comportamento médio associado ao dia da semana d, para o produto p.

Após esse ajuste, as correlações foram novamente calculadas. Como discutido na Seção 4.4, o procedimento reduziu de forma expressiva os coeficientes de correlação de diversos produtos sem relação plausível com a BANANA, confirmando que parte relevante da correlação bruta observada na Seção 3.7 decorria do padrão de calendário compartilhado.

3.9 Restrição ao domínio de FLV/hortifrúti e defasagem temporal

Mesmo após o controle do efeito de dia da semana, a lista de produtos mais correlacionados com a BANANA continuou a incluir itens sem qualquer relação plausível de negócio (por exemplo, lã de aço e biscoitos).

Como a análise de correlação residual foi conduzida simultaneamente sobre 482 produtos, é estatisticamente esperado que alguns deles apresentem correlação elevada apenas por acaso — problema de comparações múltiplas discutido na Seção 2.4.

Para mitigar esse risco e escolher um produto parceiro com justificativa de negócio plausível, a seleção final foi restrita aos produtos do mesmo departamento de FLV/hortifrúti da BANANA, identificados manualmente entre os 482 produtos elegíveis. Esse subconjunto totalizou 41 produtos, entre itens vendidos por quilograma e o item cheiro-verde, vendido por unidade.

Dentro desse subconjunto, foi selecionado o produto com maior correlação residual (mesmo dia) com a BANANA.

Como a correlação de maior magnitude no mesmo dia (defasagem zero) não pode ser utilizada como variável preditiva sem incorrer em vazamento de informação — no momento de prever a venda de BANANA de um dia, a venda do produto parceiro nesse mesmo dia ainda não é conhecida —, foi adicionalmente calculada a correlação residual do produto selecionado com a BANANA para defasagens de 1, 2 e 3 dias anteriores.

Para a modelagem, manteve-se a defasagem de maior correlação em valor absoluto dentro desse intervalo seguro.

Registra-se uma limitação metodológica desta etapa: tanto a correlação bruta (Seção 3.7) quanto a correlação residual (Seções 3.8 e 3.9) foram calculadas sobre a série completa de 90 dias, sem separar previamente um período de teste.

Um procedimento mais rigoroso realizaria a seleção do produto parceiro exclusivamente com dados anteriores ao período reservado para avaliação. Neste estudo, a escolha do produto parceiro teve acesso indireto a informação de todo o

período, incluindo os 14 dias finais posteriormente utilizados como teste dos modelos (Seção 3.11). Essa limitação é retomada na Seção 4.10.

3.10 Preparação das variáveis para modelagem

Para a própria série da BANANA, foram construídas variáveis defasadas de 1, 2 e 7 dias, além da média móvel dos 7 dias anteriores (calculada apenas com informação passada), e variáveis de calendário indicando o dia da semana e se o dia correspondia a um final de semana.

Para o modelo combinado, foram adicionadas a defasagem de 1 dia do produto parceiro, sua defasagem de maior correlação residual identificada na Seção 3.9 (quando distinta da defasagem de 1 dia) e sua média móvel dos 7 dias anteriores.

3.11 Separação temporal entre treino e teste

A avaliação preditiva preservou a ordem temporal das observações: os primeiros dias da série foram utilizados para treinamento dos modelos, e os últimos 14 dias (18 a 31 de janeiro de 2023) foram reservados exclusivamente para teste, sem participar do ajuste de nenhum modelo.

Após a remoção das primeiras observações necessárias para o cálculo das variáveis defasadas de maior janela (7 dias), o conjunto de treino resultante compreendeu 69 dias (8 de novembro de 2022 a 17 de janeiro de 2023).

3.12 Modelos de previsão

Foram comparadas seis abordagens preditivas para a série da BANANA: um modelo Naive, que repete o último valor observado; um modelo Naive sazonal, que repete o valor observado sete dias antes; uma média móvel dos 7 dias anteriores; uma regressão linear múltipla; e dois modelos de conjunto de árvores, Random Forest e Gradient Boosting.

Os três últimos modelos utilizaram as variáveis descritas na Seção 3.10, primeiro apenas com as variáveis da própria BANANA (modelos univariados). Em seguida, o melhor modelo univariado foi re-treinado incorporando também as variáveis do produto

parceiro identificado na Seção 3.9 (modelo combinado). A Seção 2.6 detalha, de forma didática, o princípio de funcionamento de cada um desses modelos.

Tabela 2 – Síntese dos modelos de previsão avaliados.

Modelo	Informações utilizadas	Finalidade
Naive	Último valor observado da BANANA	Referência mínima de comparação
Naive sazonal	Valor da BANANA em defasagem de 7 dias	Referência sazonal simples
Média móvel (7 dias)	Média dos 7 valores anteriores da BANANA	Referência de suavização
Regressão Linear	Defasagens e média móvel da BANANA, dia da semana	Modelo linear interpretável
Random Forest	Defasagens e média móvel da BANANA, dia da semana	Modelo não linear de conjunto
Gradient Boosting	Defasagens e média móvel da BANANA, dia da semana	Modelo não linear de conjunto
Melhor modelo + produto correlacionado	Variáveis do melhor modelo univariado + defasagens do produto parceiro	Testar se a série correlacionada acrescenta capacidade preditiva

Fonte: Elaborado pelo autor (2026), a partir da execução do notebook `analise_banana.ipynb`.

3.13 Complemento: previsão específica por dia da semana

Como complemento à modelagem diária genérica das seções anteriores, foi avaliada uma abordagem mais direta: em vez de prever "o próximo dia" de forma geral, cada data de teste foi prevista usando apenas o histórico do mesmo dia da semana (por exemplo, uma terça-feira foi prevista pela média das últimas quatro terças-feiras anteriores).

Essa abordagem interessa diretamente à operação do supermercado, ao permitir comparar o comportamento esperado no dia de menor venda com o comportamento esperado no dia de maior venda (identificados na Seção 4.2), apoiando decisões de

compra e reposição específicas por dia da semana. Os resultados dessa comparação são apresentados na Seção 4.11.

3.14 Métricas de avaliação

O desempenho dos modelos foi avaliado principalmente pelo Erro Absoluto Médio (MAE) e pela Raiz do Erro Quadrático Médio (RMSE). Como medida complementar, foi utilizado o Erro Percentual Absoluto Médio (MAPE).

O MAE expressa a magnitude média dos erros em unidades da variável-alvo, enquanto o RMSE atribui maior peso a erros de maior magnitude. O MAPE expressa o erro em termos percentuais, mas foi interpretado como métrica complementar devido à sua sensibilidade quando os valores observados são relativamente baixos.

Também foi calculada a proporção de previsões em que o modelo com produto correlacionado apresentou erro absoluto inferior ao modelo baseado somente na série da BANANA.

3.15 Síntese do procedimento metodológico

Em síntese, o procedimento metodológico foi composto pela preparação e análise da base transacional, definição da BANANA (soma das três variedades) como produto-alvo e construção das séries diárias.

Na sequência, o procedimento envolveu a investigação do comportamento temporal, a seleção de produtos por cobertura, a análise de correlações bruta e com controle do efeito de dia da semana, e a restrição da escolha do produto parceiro ao domínio de FLV/hortifrúti.

Por fim, o procedimento envolveu a separação temporal entre treino e teste, a construção dos modelos de previsão — incluindo o complemento de previsão por dia da semana —, e a avaliação por métricas de erro.


Os valores obtidos em cada etapa, as diferenças observadas entre os modelos e a interpretação do desempenho preditivo são apresentados na Seção 4.

4. RESULTADOS E DISCUSSÃO

4.1 Visão geral do faturamento e caracterização da série de BANANA

A Figura 5 apresenta os 15 produtos de maior faturamento no período analisado, oferecendo uma visão geral do mix de vendas da loja antes de se concentrar especificamente na BANANA.

Figura 5 – Top 15 produtos por faturamento no período de três meses analisado. O produto de maior faturamento não é a BANANA, mas itens de mercearia e bazar de maior valor unitário; a BANANA aparece entre os produtos de maior giro do hortifrúti, o que justifica seu interesse específico para este trabalho.




Fonte: Elaborado pelo autor (2026), a partir da execução do notebook `analise_banana.ipynb`.

Após a agregação diária, a série da BANANA (soma das variedades Prata, Nanica e Maçã) esteve presente em todos os 90 dias operacionais do período, totalizando 13.048,33 kg comercializados.

A quantidade média diária foi de 144,98 kg, com mediana de 149,91 kg e desvio-padrão de 35,92 kg. A menor quantidade diária registrada foi de 79,00 kg (20 de

dezembro de 2022), e a maior foi de 243,52 kg (28 de janeiro de 2023). O coeficiente de variação foi de aproximadamente 24,78%, indicando variabilidade relevante na quantidade comercializada ao longo do período.

Figura 6 – Quantidade diária comercializada de BANANA (kg) no período de 1º de novembro de 2022 a 31 de janeiro de 2023. A média do período (144,98 kg/dia) é superada em cerca de metade dos dias, com picos acima de 200 kg concentrados principalmente ao final de semana e vales abaixo de 100 kg em dias de meio de semana, especialmente terças-feiras.



Fonte: Elaborado pelo autor (2026), a partir da execução do notebook `analise_banana.ipynb`.

A Figura 6 evidencia oscilações frequentes no volume diário comercializado. Não se observa visualmente uma tendência contínua de crescimento ou redução durante os três meses analisados.


A alternância recorrente entre níveis mais altos e mais baixos de vendas motivou a investigação da existência de padrões relacionados ao calendário, apresentada a seguir.

4.2 Comportamento das vendas segundo o dia da semana

A agregação das observações segundo o dia da semana revelou diferenças expressivas na quantidade média comercializada de BANANA.

O sábado apresentou a maior quantidade média comercializada, aproximadamente 187,84 kg, enquanto a terça-feira apresentou a menor média, aproximadamente 108,57 kg. A diferença entre esses valores corresponde a aproximadamente 73% da média observada nas terças-feiras.

Figura 7 – Distribuição da quantidade diária de BANANA (kg) por dia da semana, no período de 90 dias analisado. Nota-se maior média aos sábados ($\approx 187,84$ kg) e sextas-feiras, e menor média às terças-feiras ($\approx 108,57$ kg) e domingos. A maior dispersão (caixa mais alta) ocorre à sexta-feira, o que é compatível com a proximidade do fim de semana e com uma combinação mais heterogênea de perfis de compra — de reposições pontuais a compras maiores para o fim de semana.



Fonte: Elaborado pelo autor (2026), a partir da execução do notebook `analise_banana.ipynb`.

Esses resultados fornecem evidências descritivas de um padrão semanal nas vendas de BANANA. Entretanto, essa associação não deve ser interpretada como relação causal, uma vez que outros fatores capazes de influenciar a demanda, como promoções, preços relativos, disponibilidade de estoque ou condições climáticas, não estão representados integralmente na base utilizada.


Ainda assim, o padrão identificado justificou a inclusão de variáveis de calendário nos modelos preditivos (Seção 4.6) e motivou a etapa de controle do efeito semanal na análise de correlação, discutida a seguir.

4.3 Correlação bruta entre as séries dos produtos

Após a caracterização da série da BANANA, foi investigada a associação entre seu comportamento temporal e as séries dos demais produtos.

Entre os 482 produtos elegíveis (presentes em pelo menos 90% dos 90 dias operacionais), a Figura 8 apresenta os 15 produtos com maior correlação de Pearson, no mesmo dia, com a série da BANANA.

Figura 8 – Top 15 produtos mais correlacionados (correlação bruta, mesmo dia) com a BANANA. O primeiro colocado, Cheiro Verde UN, tem correlação plausível (ambos são itens de hortifrúti); já o segundo colocado, Lã de Aço Bombril (correlação de 0,57), e o sétimo colocado, Papel Higiênico (correlação de 0,50), não têm nenhuma relação de negócio óbvia com banana, indício de que parte dessas correlações reflete apenas o calendário de compras da loja, e não uma relação real entre os produtos.



Fonte: Elaborado pelo autor (2026), a partir da execução do notebook `analise_banana.ipynb`.

Tabela 3 – Produtos com maior correlação bruta (mesmo dia) com a BANANA.


Produto	Correlação
Cheiro Verde UN	0,58
Lã de Aço Bombril Eco SC 60G 8X1	0,57
Maçã Nacional KG	0,55
Caldo em Tablete Maggi Galinha CX 114G 12X1	0,55
Colorífico em Pó Kimimo SC 100G	0,55
Pão Rabelo Hambúrguer PC 400G	0,54
Papel Higiênico Floral Perfumado PC 30MT 4X1	0,50
Creme Dental Colgate T Ação Menta Original CX 90G	0,48

Fonte: Elaborado pelo autor (2026), a partir da execução do notebook `analise_banana.ipynb`.

Chama atenção, na Figura 8 e na Tabela 3, a presença de produtos sem qualquer relação plausível de negócio com a BANANA, como lã de aço, papel higiênico e creme dental.

A investigação da correlação em defasagens de -3 a +3 dias para os cinco produtos mais correlacionados no mesmo dia mostrou que, para praticamente todos eles, a correlação é elevada apenas na defasagem zero e cai abruptamente nas demais defasagens. Esse padrão é compatível com um efeito de calendário compartilhado, e não com uma relação de defasagem genuína entre os produtos.

Figura 9 – Matriz de correlação de Pearson entre os 10 produtos mais correlacionados (mesmo dia) e a BANANA. As células em tons de vermelho escuro na diagonal e nas primeiras posições mostram correlações próximas de 0,50 a 0,60 entre a maioria desses produtos entre si — não só com a BANANA —, reforçando a hipótese de um fator comum (o calendário semanal de vendas) por trás dessas associações, em vez de relações específicas de cada par de produtos.




Fonte: Elaborado pelo autor (2026), a partir da execução do notebook `analise_banana.ipynb`.

4.4 Efeito do controle do dia da semana sobre a correlação

Para reduzir a influência desse padrão de calendário compartilhado, foi removido de cada série o comportamento médio correspondente ao dia da semana. A correlação foi recalculada sobre as séries residuais resultantes.

Figura 10 – Top 15 produtos mais correlacionados com a BANANA após remoção do efeito de dia da semana (correlação residual). O primeiro colocado, Lã de Aço Bombril (0,49), permanece no topo mesmo sem relação plausível de negócio, evidenciando um provável falso positivo estatístico; entre os cinco primeiros, apenas Abóbora Cabocla KG (terceiro colocado, 0,42) tem lógica de negócio como produto de hortifrúti.



Fonte: Elaborado pelo autor (2026), a partir da execução do notebook `analise_banana.ipynb`.

Ainda que a remoção do efeito semanal tenha alterado a composição e a magnitude das correlações em relação à Figura 8, o topo da lista residual continuou a incluir um produto sem relação plausível com a BANANA — lã de aço, com correlação residual de 0,49, a maior entre os 482 produtos avaliados.


Esse resultado é compatível com o problema de comparações múltiplas discutido na Seção 2.4: ao se testar simultaneamente 482 correlações, é estatisticamente esperado que algumas delas apareçam elevadas por acaso, mesmo sem qualquer relação real com a BANANA.

Esse achado motivou a restrição da escolha final do produto parceiro ao domínio de FLV/hortifrúti, descrita a seguir.

4.5 Seleção do produto parceiro dentro do domínio de FLV/hortifrúti

Entre os 482 produtos elegíveis, 41 pertencem ao mesmo departamento de FLV/hortifrúti da BANANA. A Figura 11 apresenta a correlação residual desses 41 produtos com a BANANA.

Figura 11 – Produtos de FLV/hortifrúti mais correlacionados com a BANANA (correlação residual, sem efeito de dia da semana). Abóbora Cabocla KG lidera com correlação de 0,42, seguida por Cheiro Verde UN (0,38) e Maça Nacional KG (0,35); a maioria dos demais itens frutícolas (goiaba, mamão, laranja) apresenta correlações entre 0,25 e 0,35, sugerindo um comportamento de compra conjunta moderado entre diferentes itens de hortifrúti.



Fonte: Elaborado pelo autor (2026), a partir da execução do notebook *analise_banana.ipynb*.

Tabela 4 – Top 10 produtos de FLV/hortifrúti mais correlacionados (correlação residual) com a BANANA.

Produto	Correlação residual (mesmo dia)
Abóbora Cabocla KG	0,42
Cheiro Verde UN	0,38
Maçã Nacional KG	0,35
Pimenta de Cheiro KG	0,34
Laranja KG	0,34
Brócolis KG	0,33
Pera Danjou KG	0,33
Cebola Branca KG	0,28
Mamão Formosa KG	0,27
Goiaba KG	0,25

Fonte: Elaborado pelo autor (2026), a partir da execução do notebook `analise_banana.ipynb`.


O produto com maior correlação residual dentro desse domínio foi a ABÓBORA CABOCLA KG, com correlação de 0,42 no mesmo dia.

Como essa correlação contemporânea não pode ser utilizada como variável preditiva sem incorrer em vazamento de informação (Seção 3.9), foi calculada a correlação residual defasada em 1, 2 e 3 dias entre a Abóbora Cabocla e a BANANA.

O resultado indicou correlação máxima de 0,342 na defasagem de 1 dia — ou seja, a venda de Abóbora Cabocla em um dia guarda associação com a venda de BANANA no dia seguinte. Essa defasagem de 1 dia foi a utilizada na modelagem combinada apresentada na Seção 4.7.

Figura 12 – Série diária de BANANA (eixo esquerdo, em amarelo) e de Abóbora Cabocla KG (eixo direito, em azul) no período de três meses analisado. Os dois produtos acompanham picos semelhantes em vários trechos da série, sobretudo em dezembro e janeiro, consistente com a correlação residual de 0,42 identificada — ainda que também

existam períodos de descolamento entre as duas séries, o que limita o poder explicativo dessa única variável parceira.



Fonte: Elaborado pelo autor (2026), a partir da execução do notebook *analise_banana.ipynb*.

4.6 Avaliação dos modelos univariados


Foram avaliadas seis estratégias de previsão. O período final, compreendido entre 18 e 31 de janeiro de 2023, foi reservado para avaliação, totalizando 14 observações.

Tabela 5 – Métricas de desempenho dos modelos avaliados no período de teste (14 dias).

Modelo	MAE (kg)	RMSE (kg)	MAPE (%)
Naive (último valor)	60,72	65,76	47,90
Naive sazonal (lag 7)	41,71	53,21	29,89
Média móvel (7 dias)	42,15	51,01	31,70
Regressão Linear (univariado)	37,43	43,51	29,30
Random Forest (univariado)	35,02	41,06	25,58
Gradient Boosting (univariado)	35,10	42,16	26,17
Random Forest + Abóbora Cabocla	35,03	40,50	25,81

Fonte: Elaborado pelo autor (2026), a partir da execução do notebook `analise_banana.ipynb`.

Figura 13 – Comparação do RMSE entre os modelos univariados avaliados, do maior para o menor erro. O modelo Naive (último valor) apresenta o dobro do erro do melhor modelo (65,76 kg contra 41,06 kg do Random Forest), evidenciando o ganho de se usar variáveis defasadas e de calendário em vez de uma simples repetição do último valor observado.




Fonte: Elaborado pelo autor (2026), a partir da execução do notebook `analise_banana.ipynb`.

Todos os modelos baseados em variáveis defasadas e de calendário superaram as referências simples (Naive, Naive sazonal e Média móvel).

Entre os modelos univariados, o Random Forest apresentou o melhor desempenho, com MAE de 35,02 kg, RMSE de 41,06 kg e MAPE de 25,58%, seguido de perto pelo Gradient Boosting e, com desempenho inferior, pela Regressão Linear.

Esse resultado indica que a relação entre as variáveis defasadas da própria BANANA e sua venda futura possui componentes não inteiramente lineares, capturados de forma mais eficaz pelos modelos de conjunto de árvores (Seção 2.6).

Figura 14 – Valores reais (linha cinza) e previstos pelo melhor modelo univariado, Random Forest (linha amarela), no período de teste de 14 dias. O modelo acompanha razoavelmente a direção das oscilações, mas subestima os dois maiores picos de venda do período (27 e 28 de janeiro, próximo de 220-240 kg), reflexo direto do RMSE de 41,06 kg reportado na Tabela 5.




Fonte: Elaborado pelo autor (2026), a partir da execução do notebook `analise_banana.ipynb`.

4.7 Modelo combinado: BANANA e Abóbora Cabocla

O modelo Random Forest, melhor modelo univariado, foi re-treinado incorporando as variáveis defasadas da Abóbora Cabocla (Seção 4.5): sua defasagem de 1 dia e sua média móvel dos 7 dias anteriores.

O modelo combinado apresentou MAE de 35,03 kg, RMSE de 40,50 kg e MAPE de 25,81% no mesmo período de teste (Tabela 5).

Figura 15 – Comparação entre valores reais, previsão do modelo univariado (linha cinza tracejada) e previsão do modelo combinado BANANA + Abóbora Cabocla (linha verde) no período de teste. As duas curvas de previsão são muito próximas entre si na maior parte dos 14 dias, com pequenas diferenças concentradas nos dias de maior oscilação da venda real, consistente com o ganho reduzido de RMSE (1,4%) reportado a seguir.




Fonte: Elaborado pelo autor (2026), a partir da execução do notebook `analise_banana.ipynb`.

Em relação ao Random Forest univariado, o modelo combinado apresentou redução de RMSE de aproximadamente 1,4% (de 41,06 kg para 40,50 kg).

O MAE, por outro lado, permaneceu praticamente inalterado (35,02 kg para 35,03 kg), e o MAPE apresentou leve piora (de 25,58% para 25,81%). O modelo combinado apresentou erro absoluto menor que o modelo univariado em 7 das 14 previsões do período de teste, ou seja, em exatamente metade dos dias avaliados.

Figura 16 – Importância das variáveis no modelo Random Forest combinado. A defasagem de 7 dias da própria BANANA concentra cerca de 31% da importância total, seguida pela defasagem de 1 dia ($\approx 21\%$) e pela defasagem de 2 dias ($\approx 17\%$); juntas, as três defasagens da própria BANANA somam quase 70% da importância do modelo. A defasagem de 1 dia da Abóbora Cabocla contribui com apenas $\approx 6,5\%$, e sua média móvel de 7 dias com $\approx 4\%$, o que ajuda a explicar por que sua inclusão trouxe um ganho pequeno de desempenho.



Fonte: Elaborado pelo autor (2026), a partir da execução do notebook `analise_banana.ipynb`.

Essa distribuição de importância é coerente com a magnitude modesta do ganho observado no RMSE: o produto parceiro contribui com uma fração de informação adicional, mas o histórico da própria BANANA permanece como o principal preditor de sua venda futura.

4.8 Discussão dos resultados

Os resultados permitem responder à questão central deste estudo com algumas ressalvas.

A análise exploratória demonstrou que existem produtos cujas séries temporais apresentam associação estatística com as vendas de BANANA. Também foram identificadas associações defasadas, indicando que informações anteriores de determinadas séries podem estar relacionadas ao comportamento posterior da variável-alvo.

Entretanto, a existência de correlação não implica necessariamente ganho preditivo.

Ao restringir a busca ao domínio de FLV/hortifrúti e utilizar apenas informação defasada, foi identificado um produto — a Abóbora Cabocla — cuja inclusão produziu uma melhora real, ainda que pequena e não uniforme entre as métricas: houve redução de RMSE, mas não de MAE, e leve piora do MAPE.

O modelo combinado também não superou o univariado na maioria dos dias de teste, tendo vencido em exatamente metade deles.

Cabe reforçar, como registrado na Seção 3.9, que a seleção do produto parceiro utilizou a série completa de 90 dias, incluindo o período posteriormente reservado para teste. Esse procedimento é menos rigoroso do que uma seleção realizada exclusivamente com dados anteriores ao período de teste.

Esse fato pode ter contribuído, ainda que discretamente, para uma estimativa levemente otimista do ganho preditivo do produto parceiro. Assim, o valor de aproximadamente 1,4% de redução de RMSE deve ser interpretado como um limite superior aproximado, e não como uma estimativa definitiva do benefício de se combinar séries correlacionadas para a previsão da BANANA nesta base de dados.

4.9 Implicações gerenciais para produtos perecíveis

Embora os ganhos preditivos observados tenham sido reduzidos, a previsão de demanda permanece relevante para a gestão de produtos perecíveis. Em ambientes varejistas, estimativas de demanda podem apoiar decisões de compra, reposição e dimensionamento de estoques, contribuindo para equilibrar disponibilidade e risco de perdas.

Os resultados deste estudo não permitem quantificar diretamente redução de desperdício, economia financeira ou retorno sobre investimento, pois a base analisada não contém informações de estoque, ruptura, descarte, custo de aquisição ou margem.

Assim, qualquer impacto operacional deve ser tratado como possibilidade de aplicação, e não como resultado comprovado pelo experimento.

O principal valor gerencial do estudo está na demonstração de um procedimento de previsão que respeita a ordem temporal dos dados e evita estimativas excessivamente otimistas — cuidados que, se não observados, poderiam levar a conclusões enganosas, como ilustrado pela diferença entre a correlação bruta e a correlação residual (Seções 4.3 e 4.4).

4.10 Limitações do estudo

Uma limitação relevante está relacionada à extensão temporal da base. O conjunto compreende aproximadamente três meses de vendas, resultando em apenas 90 observações operacionais para a série diária da BANANA e 69 dias de treinamento efetivo.

Esse intervalo permite investigar padrões de curto prazo, mas é insuficiente para avaliar adequadamente sazonalidades de maior duração, como variações anuais ou relacionadas às diferentes estações do ano.

Outra limitação decorre das variáveis disponíveis. A base não contém informações explícitas sobre promoções, estoque disponível, ruptura de produtos, condições climáticas, feriados operacionais, campanhas comerciais ou outros fatores externos que podem influenciar a demanda.

Como discutido nas Seções 3.9 e 4.8, a seleção do produto parceiro não foi realizada exclusivamente com dados anteriores ao período de teste, o que representa uma limitação metodológica relevante em relação a um procedimento de avaliação preditiva mais rigoroso.

Além disso, os dados correspondem a apenas uma loja, o que restringe a generalização dos resultados para outros estabelecimentos ou contextos varejistas.

A quantidade limitada de observações também motivou a utilização de modelos relativamente simples e interpretáveis. Com séries históricas mais extensas, trabalhos futuros poderão avaliar modelos estatísticos clássicos com variável exógena, como o SARIMAX (FERREIRA et al., 2017), não utilizados neste estudo em razão de uma restrição do ambiente computacional de execução.

4.11 Complemento: previsão específica por dia da semana

O desempenho geral dos modelos das seções anteriores é modesto: mesmo o melhor modelo (Random Forest) mantém RMSE em torno de 41 kg, para uma média diária de aproximadamente 145 kg. Uma hipótese é que o modelo diário genérico não aproveita ao máximo o forte padrão semanal descrito na Seção 4.2.


Como complemento, foi avaliada uma abordagem mais direta e de interesse operacional imediato: prever cada data de teste usando apenas o histórico do mesmo dia da semana, com foco particular no dia de menor venda (terça-feira) e no dia de maior venda (sábado), identificados na Seção 4.2.

Tabela 6 – Métricas do modelo de previsão específico por dia da semana, em comparação com o melhor modelo geral.

Modelo	MAE (kg)	RMSE (kg)	MAPE (%)
Random Forest (geral, univariado)	35,02	41,06	25,58
Média das últimas 4 ocorrências do mesmo dia da semana	40,24	47,03	31,66

Fonte: Elaborado pelo autor (2026), a partir da execução do notebook `analise_banana.ipynb`.

Figura 17 – Erro absoluto médio por dia da semana, no período de teste, comparando o modelo específico por dia da semana (verde) com o Random Forest geral (azul). O Random Forest apresenta erro menor na maioria dos dias, com destaque para a terça-feira (20,59 kg contra 39,21 kg do modelo por dia da semana) — justamente o dia de menor venda média, de maior interesse operacional para evitar excesso de compra. Já na quinta-feira, o modelo por dia da semana tem vantagem clara (13,21 kg contra 19,27 kg), e no sábado (dia de maior venda) os dois modelos ficam praticamente empatados (39,56 kg e 39,77 kg, respectivamente).



Fonte: Elaborado pelo autor (2026), a partir da execução do notebook *analise_banana.ipynb*.

De forma agregada, o modelo específico por dia da semana teve desempenho pior que o Random Forest geral (RMSE de 47,03 kg contra 41,06 kg). Ou seja, tratar cada dia da semana de forma isolada, usando apenas uma média simples das últimas ocorrências, não superou o modelo geral que já incorpora o dia da semana como uma entre várias variáveis explicativas.

Ainda assim, o exercício tem valor prático direto para a operação da loja: nas duas terças-feiras do período de teste, a venda real foi de 79,05 kg e 147,66 kg, enquanto nos dois sábados a venda real foi de 180,99 kg e 243,52 kg.

Essa diferença — de mais de 100 kg, em média, entre o dia de menor e o dia de maior venda — reforça que qualquer estratégia de compra e reposição de BANANA

deveria diferenciar claramente terças-feiras de sábados, independentemente do modelo estatístico utilizado, sob risco de gerar tanto quebra (compra excessiva em dias de baixa demanda) quanto ruptura (compra insuficiente em dias de alta demanda).

5. CONCLUSÃO

Este estudo teve como objetivo investigar se a utilização de informações provenientes das séries temporais de outros produtos poderia contribuir para melhorar a previsão da quantidade diária comercializada de BANANA em um supermercado.

A análise exploratória permitiu identificar características importantes da série de vendas do produto-alvo. Foram observadas variações relevantes na quantidade comercializada ao longo do período, além de diferenças expressivas entre os dias da semana — com o sábado apresentando quantidade média aproximadamente 73% superior à da terça-feira, dia de menor venda.

Esses resultados justificaram a utilização de informações históricas da própria BANANA e de variáveis de calendário na construção dos modelos de previsão.

A análise das séries dos demais produtos também identificou associações contemporâneas e defasadas com as vendas de BANANA. Verificou-se, porém, que parte dessas correlações estava relacionada a padrões temporais compartilhados, especialmente ao comportamento semanal das vendas — o produto mais correlacionado entre todos os 482 avaliados, um item de limpeza, não tinha nenhuma relação plausível com a BANANA.

Por esse motivo, foi aplicado um procedimento para reduzir a influência do dia da semana e a escolha do produto parceiro foi restrita a itens do mesmo departamento de FLV/hortifrúti, resultando na seleção da ABÓBORA CABOCLA KG, com defasagem de um dia.

Entre os modelos preditivos avaliados, o Random Forest univariado, baseado somente no histórico da própria BANANA, apresentou o melhor desempenho, com MAE de 35,02 kg, RMSE de 41,06 kg e MAPE de 25,58% no período de teste de 14 dias.

Ao incorporar as variáveis defasadas da Abóbora Cabocla, o modelo combinado apresentou RMSE de 40,50 kg — uma redução de aproximadamente 1,4% — mas MAE praticamente inalterado e MAPE ligeiramente superior, além de menor erro absoluto em apenas metade das previsões do período de teste (7 de 14 dias).

Dessa forma, os resultados indicam que séries temporais de outros produtos podem conter informações associadas ao comportamento futuro das vendas de BANANA. Contudo, para a base e o período analisados, não foram encontradas evidências suficientes para afirmar que a inclusão dessas séries proporciona melhoria robusta e consistente na capacidade preditiva do modelo.

Como complemento à hipótese principal, foi avaliada uma previsão específica por dia da semana, de interesse direto para a operação de compra e reposição da loja. Essa abordagem simples não superou o Random Forest geral (RMSE de 47,03 kg contra 41,06 kg), mas evidenciou de forma quantitativa a diferença entre os dias de menor e de maior venda: nas duas terças-feiras do período de teste, a venda ficou entre 79,05 kg e 147,66 kg; nos dois sábados, entre 180,99 kg e 243,52 kg.

Além da avaliação da hipótese principal, o estudo evidenciou a importância da separação temporal entre seleção de variáveis, treinamento e teste em problemas de previsão, bem como do controle de correlações espúrias decorrentes de padrões de calendário compartilhados e de comparações múltiplas.

Como principal limitação, destaca-se o curto período histórico disponível, correspondente a aproximadamente três meses de vendas. Essa quantidade de observações restringe a avaliação da estabilidade das correlações e impossibilita uma análise adequada de padrões sazonais de maior duração.

Além disso, a base corresponde a uma única loja e não contém algumas variáveis potencialmente relevantes para a demanda, como disponibilidade de estoque, rupturas, promoções, condições climáticas e outros fatores externos.

Como trabalhos futuros, recomenda-se ampliar o período histórico analisado, repetir a seleção do produto parceiro utilizando exclusivamente dados anteriores ao período de teste, incorporar dados de outras lojas e avaliar modelos estatísticos clássicos com variável exógena, como o SARIMAX (FERREIRA et al., 2017).

Recomenda-se ainda aprofundar a abordagem de previsão por dia da semana apresentada na Seção 4.11, testando modelos mais elaborados do que a média

simples das últimas ocorrências, especialmente para os dias de maior interesse operacional (terça-feira e sábado).

Do ponto de vista gerencial, o estudo não quantificou redução de perdas ou retorno financeiro, mas estabelece uma base metodológica para aplicações futuras em planejamento de compras, reposição e estoques de produtos perecíveis. A mensuração desses efeitos dependerá da incorporação de variáveis operacionais e econômicas não disponíveis na base atual.

Em síntese, os resultados sugerem que séries temporais de produtos correlacionados podem acrescentar informação à previsão da demanda de BANANA. Entretanto, no período e na base analisados, essa contribuição apresentou magnitude reduzida e não demonstrou melhoria preditiva robusta e consistente quando submetida a uma avaliação temporal rigorosa.

REFERÊNCIAS

CEARÁ. Secretaria do Desenvolvimento Econômico e Trabalho (SDE). Cadeias produtivas do agronegócio. Governo do Estado do Ceará, 2026. Disponível em: <https://www.ce.gov.br/sde/negocios/agronegocio/cadeias-produtivas-do-agronegocio/>. Acesso em: 01 set. 2026.

EMBRAPA. Banana. Empresa Brasileira de Pesquisa Agropecuária, Embrapa Mandioca e Fruticultura, 2026. Disponível em: <https://www.embrapa.br/web/mandioca-e-fruticultura/cultivos/banana>. Acesso em: 01 set. 2026.

FERREIRA, P. G. C. et al. Análise de séries temporais em R: curso introdutório. São Paulo: Elsevier: FGV IBRE, 2017.

GÉRON, A. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow. 3. ed. Sebastopol: O'Reilly Media, 2022.

IBGE. Fortaleza (CE): panorama municipal. Instituto Brasileiro de Geografia e Estatística, Cidades@, 2026. Disponível em: <https://cidades.ibge.gov.br/brasil/ce/fortaleza/pesquisa/15/11882?ano=2024>. Acesso em: 01 set. 2026.

OLIVEIRA, R. R.; SILVA, C. da; SILVA, J. S. F.; SOUSA, A. R. dos S. Análise de séries temporais. Porto Alegre: Sagah, 2021.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011.

SENA, J. V. C. Aspectos da produção e mercado da banana no Nordeste. Informe Rural ETENE, Fortaleza, ano 5, n. 10, jul. 2011. Banco do Nordeste do Brasil, Escritório Técnico de Estudos Econômicos do Nordeste.